

# 9º CONGRESSO BRASILEIRO DE PESQUISA E DESENVOLVIMENTO EM PETRÓLEO E GÁS



**9º CONGRESSO**  
Brasileiro de P&D em  
**PETRÓLEO E GÁS**

**Maceió, AL**  
de 09 a 11 de novembro  
**2017**

Realização:



**ABPG**  
ASSOCIAÇÃO BRASILEIRA DE P&D EM  
PETRÓLEO E GÁS



## **TÍTULO DO TRABALHO:**

Conjunção da Transformada Wavelet Discreta Com As Redes Neurais Artificiais Na Estimativa Do Preço De Gás Natural

## **AUTORES:**

Bruno Carlos Vieira dos Santos; Lucas Costa Barreto; Tiago Patrício da Silva; Samuel Vitor Saraiva; Frede de Oliveira Carvalho

## **INSTITUIÇÃO:**

Universidade Federal de Alagoas - UFAL

*Este Trabalho foi preparado para apresentação no 8º Congresso Brasileiro de Pesquisa e Desenvolvimento em Petróleo e Gás - 9º PDPETRO, realizado pela Associação Brasileira de P&D em Petróleo e Gás - ABPG, no período de 09 a 11 de novembro de 2017, em Maceió/AL. Esse Trabalho foi selecionado pelo Comitê Científico do evento para apresentação, seguindo as informações contidas no documento submetido pelo(s) autor(es). O conteúdo do Trabalho, como apresentado, não foi revisado pela ABPG. Os organizadores não irão traduzir ou corrigir os textos recebidos. O material conforme, apresentado, não necessariamente reflete as opiniões da Associação Brasileira de P&D em Petróleo e Gás. O(s) autor(es) tem conhecimento e aprovação de que este Trabalho seja publicado nos Anais do 9º PDPETRO.*

## CONJUNÇÃO DA TRANSFORMADA WAVELET DISCRETA COM AS REDES NEURAIS ARTIFICIAIS NA ESTIMATIVA DO PREÇO DE GÁS NATURAL

### Abstract

Natural gas is a resource with a wide scope of application; its use goes from the generation of electric energy to the use in combustion engines in the transportation sector and in the production of flames, heat and steam. Its versatility has been reflected in the continuous increase in its consumption and exploration. In this context, techniques that allow the prognosis of natural gas prices and consequently contribute to decision making have become increasingly important since this natural resource has great influence in several sectors of the world economy. With this motivation, this work proposes the study of a prediction model based on the time series treatment, through the conjunction of signal processing techniques, through the discrete wavelet transform (TWD), with models based on intelligent systems, through the use of artificial neural networks (ANNs) to forecast, in the short term (daily), the price of natural gas. In the system used, the time series of prices is decomposed into components of approximation and details, through the discrete wavelet transform, and the series resulting from the decomposition are presented as input variables of the neural network, which is responsible for establishing the mathematical model that makes the forecast. The results obtained by the estimation, when compared with the effective quotation, demonstrate a high degree of adherence of the model for forecasting the price one day ahead. The coefficient of determination,  $R^2$ , presented the value of 0.976 in the implementation phase and the root of the mean square error, RMSE, returned the value of 0.0158 \$ / MMBTU.

### Introdução

Atualmente, o gás natural é um item substancial do fornecimento mundial de energia, sendo este uma das fontes de energia mais limpas, seguras e versáteis. Segundo a *American Public Gas Association*, hoje, este combustível fóssil é responsável por suprir mais de metade da energia consumida por clientes residenciais e comerciais e cerca de 40% da energia utilizada pela indústria dos Estados Unidos. Dessa forma, uma vez que o gás natural é o combustível fóssil de queima menos agressivo, este tem desempenhado um papel fundamental na busca por atingir os objetivos nacionais de um ambiente mais limpo (LIANG et. al., 2012).

De acordo com Wong-Parodi, Dale e Lekovi (2006), prever com precisão os preços do gás natural pode favorecer o investimento, a negociação de contratos de importação e exportação, assim como também apoiar a elaboração de políticas voltadas ao setor. Dessa forma, a aplicação de técnicas para obtenção de prognósticos, através do estudo de históricos, pode ser uma ferramenta importante no sistema de apoio à tomada de decisões relacionadas aos negócios de petróleo e gás.

Nos últimos anos, metodologias baseadas em aprendizado de máquina, a exemplo das redes neurais artificiais (RNA), têm sido empregadas em diversos estudos para prognósticos de preços, visto que estes modelos possuem grande versatilidade, o que lhes permitem ser aplicados a qualquer série de dados temporais (JIN; KIM, 2015). Ademais, métodos de regressão estatística, como a *autoregressive integrated moving-average* (ARIMA) e o *generalized autoregressive conditional heteroskedacity* (GARCH), também tem sido utilizados devido à sua simplicidade e bom desempenho frente a este tipo de problema. Não obstante, vários estudos têm demonstrado que as redes neurais artificiais podem superar os modelos de regressão estatística, além de permitir uma análise mais profunda de grandes conjuntos de dados, particularmente aqueles que tendem a flutuar bastante dentro um curto espaço de tempo (KHUAT et. al., 2016).

Desde o início do século, técnicas baseadas em análise espectral, como transformada wavelet, têm sido combinadas com modelos de séries temporais como ferramenta de pré-processamento de dados, tendo como objetivo extrair características importantes que auxiliem na modelagem da série temporal (JIN; KIM, 2015). Como demonstrado por Ashish e Rashmi (2011), em particular, o uso desta técnica potencializou a habilidade de generalização das redes neurais, visto que o modelo em estudo foi capaz de fornecer melhores resultados na previsão da série temporal em questão.

Dessa forma, esse trabalho investiga a eficiência de um modelo empírico de previsão, baseado em sistemas inteligentes, mais especificamente, nas redes neurais artificiais em conjunção com a transformada wavelet discreta (TWD) como ferramenta de pré-processamento de dados de séries temporais, aplicado à série diária de preços de gás natural do *Henry hub*, visto que esse centro de distribuição é o ponto de referência para diversos tipos de contratos, como por exemplo, os da New York Mercantile Exchange (NYMEX).


## Metodologia

### Transformada wavelet

A transformada wavelet é um método matemático que permite mapear um conjunto de dados temporalmente bem localizados, no domínio da frequência e do tempo. Por definição, uma wavelet seria uma função em forma de onda, que possui energia finita, sendo a área sob seu gráfico igual à zero (referencia). Obedecendo a estes parâmetros, diversas funções podem ser definidas como wavelets, estas podendo assumir diversos formatos. A Figura 2 abaixo traz a representação gráfica de algumas delas.

A equação 1 representa a transformada propriamente dita, que nada mais é do que um cálculo integral envolvendo uma wavelet-mãe, escolhida previamente, e o conjunto de dados no domínio do tempo. Na equação 1,  $\Psi_{a,b}(t)$  é a wavelet-mãe, e os parâmetros  $a$  e  $b$ , dilatação e deslocamento respectivamente, são para o ajuste de seu tamanho e posição no tempo. Através deles é possível a obtenção de várias versões da wavelet-mãe escolhida, que por sua vez serão superpostas para representar o conjunto de dados no novo domínio.

Figura 2: Exemplos de wavelets. Fonte: Krishna (2013)




$$W_f(a,b) = \int_{-\infty}^{+\infty} f(t)\Psi_{a,b}(t)dt \quad (1)$$

A literatura tem reportado o uso recorrente de duas transformadas wavelet especificamente: a transformada wavelet contínua – TWC e a transformada wavelet discreta – TWD. Na transformada wavelet contínua, os parâmetros  $a$  e  $b$  são variados continuamente, podendo assumir quaisquer valores. Já na transformada wavelet discreta, estas duas variáveis podem ser escolhidas apenas

baseadas em potências de dois, o que otimiza o processo, pois o tempo necessário para o cálculo é reduzido e, além disso, sem que haja perda de acuracidade na representação. (referencia).

A TWD, particularmente, realiza a decomposição da série original em outras séries, de diferentes frequências, que quando combinadas resultam na série inicial. As componentes resultantes da decomposição que possuem alta frequência são conhecidas como detalhes, já as componentes de mais baixa frequência são nomeadas de aproximações. A quantidade de séries geradas na decomposição depende do nível escolhido para o processo. A transformada no primeiro nível produz uma componente de detalhe (D1) e outra de aproximação (A1). Este processo pode ser repetido novamente, dessa vez para a componente de aproximação (A1), que dará origem a uma nova componente de baixa frequência (A2) e a outra de mais alta frequência (D2). Todo esse procedimento pode ser representado na Figura 3.

Figura 3: Decomposição wavelet até o terceiro nível de detalhe. Fonte: Autores



Nesse estudo, a série diária de preços do gás natural foi decomposta até o terceiro nível utilizando a wavelet de Meyer. As componentes resultantes da transformada foram usadas como entradas para a rede neural para realização da previsão do preço desejado, um dia à frente.

### Redes Neurais Artificiais

As redes neurais artificiais são dispositivos computacionais que reproduzem o sistema de processamento de informação cerebral (Haykin, 2001). Sua atividade principal é extrair informações úteis a partir de um conjunto de dados que caracteriza um fenômeno, um sistema ou uma ocorrência e usar essas informações no futuro.


Estes dispositivos são muito utilizados na modelagem de sistemas altamente não lineares. Além disso, possuem alta capacidade de processamento paralelo, robustez, habilidade de generalização e tolerância ao ruído, o que os faz capazes de realizar tarefas de agrupamento, aproximação de função, previsão e associação de padrões. Os modelos neurais artificiais que possuem tais características são desejáveis por que: (a) a não linearidade permite melhor ajuste aos dados, (b) a insensibilidade ao ruído leva a predição exata na presença de dados incertos e erros de medição, (c) a aprendizagem e adaptabilidade permitem que o sistema atualize ou modifique sua estrutura interna em resposta à mudança do ambiente, e (d) a generalização permite a aplicação do modelo a dados desconhecidos.

A peça mais básica de uma rede neural é o neurônio artificial, que está representado na Figura 4. O neurônio de uma rede recebe um conjunto de dados de entrada, que são variáveis do sistema. Essas variáveis, por sua vez, são ponderadas através de pesos, isto é, elementos que são responsáveis por definir grau de importância de cada variável na resposta final de saída do neurônio. Uma vez que as entradas são ponderadas, o operador somatório realiza uma combinação linear entre os pesos e as respectivas entradas. O resultado disso, denominado campo local induzido,  $u_k$ , é propagado, somado a um escalar chamado bias,  $b_k$ , e então adentra uma função  $\phi(\cdot)$  que é responsável por restringir o intervalo de saída do seu neurônio.

Uma vez que haja mais de um neurônio conectado às entradas e estes, por sua vez, se liguem a outros neurônios em camadas mais internas, se configura o que se conhece por rede neural.

A rede neural "aprende" a realizar a tarefa para a qual foi designada através de um processo chamado de treinamento, que nada mais é do que o reajuste dos vetores de pesos à medida que as amostras do conjunto de dados são apresentadas à rede. Dessa forma, o objetivo é produzir saídas que se aproximem ao máximo dos valores reais. Para realização do treinamento, que matematicamente, hoje, se trata de uma otimização, existem alguns algoritmos já estabelecidos que apresentam características peculiares nas suas utilizações. Dentre eles, dois são bastante conhecidos devido ao recorrente uso na literatura. O primeiro é o método de retropropagação do erro, com a regra do delta generalizado, que é um método de gradiente descendente, o segundo é o método de Levenberg-Marquadt, baseado no método quasi-Newton.

Figura 4: Neurônio Artificial. Fonte: Haykin (2001)




Na modelagem de problemas que envolvem séries temporais, muitas vezes, as redes neurais são preparadas para atuar como sistemas autorregressivos. Isso significa que estas são treinadas para relacionar respostas conhecidas do sistema que, nesse caso, são os preços de gás natural registrados diariamente, a valores passados da própria série. Sendo  $y(t)$  o preço do gás natural em um determinado tempo  $t$ , a estratégia é realizar a previsão para  $y(t+1)$ , através de informações do sistema em instantes de tempo anteriores. Sendo assim,  $y(t+1)$  pode ser escrito como:

$$y(t+1) = f(y(t), y(t-1), \dots, y(t-n))$$

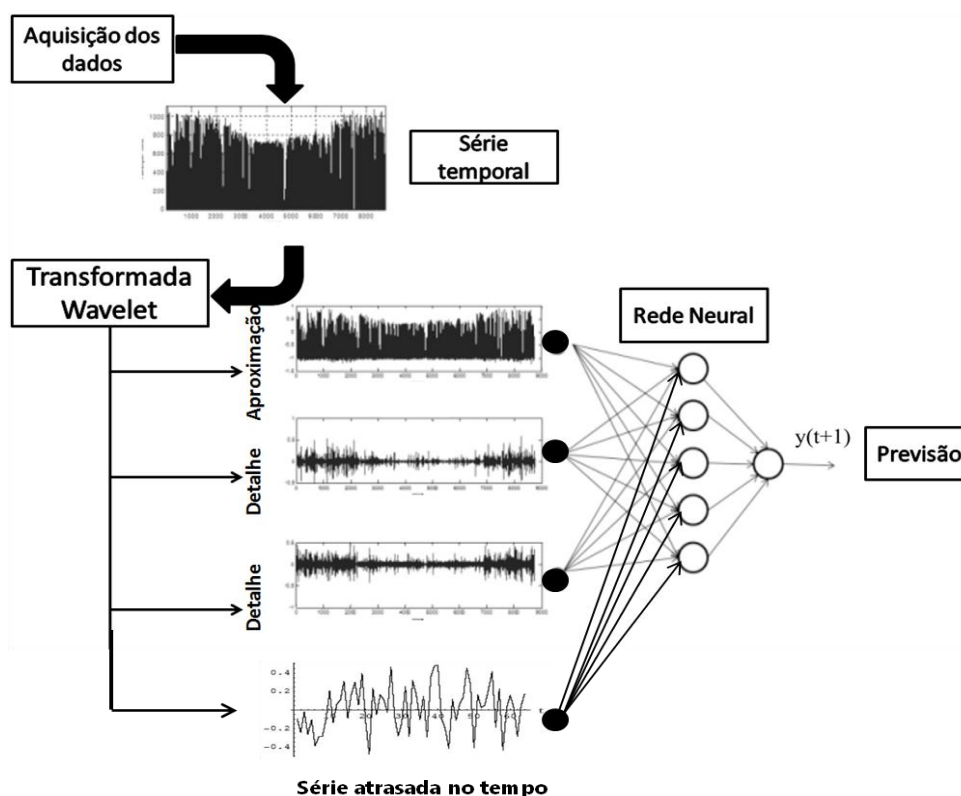
Na qual  $n$  é a ordem do preditor, que representa a quantidade de amostras passadas necessárias para construção do modelo e estimação do valor desejado. Nesse trabalho, esse modelo autorregressivo é implementado utilizando uma arquitetura *feedforward*, não havendo então a necessidade de recorrência na saída da rede. Além disso, os dados de entrada foram as resultantes da decomposição wavelet e também valores passados da própria série. A ordem do preditor foi testada para valores de 1 a 7 para cada componente de entrada e também foram testadas várias funções wavelet-mãe. O algoritmo de treinamento foi o de regularização bayesiana e a rede neural continha um único neurônio em sua camada intermediária, com a função de ativação tangente-sigmoide. A Figura 5 exemplifica o modelo de rede neural utilizada.

Figura 5: Rede Neural Autorregressiva.



A metodologia empregada neste trabalho pode ser resumida pelo fluxograma da Figura 1 abaixo:

Figura 1: Fluxograma da metodologia



Todos os modelos foram construídos utilizando ambiente MATLAB.

## Resultados e Discussão

Primeiramente, algumas famílias de wavelet foram testadas para um preditor de ordem 1, a fim de se escolher a que melhor representasse os dados da série temporal após a decomposição. Os resultados foram baseados no menor erro quadrático médio - RMSE produzido pelo modelo.

A partir desses testes, foi possível constatar que o modelo que utilizou a wavelet de Meyer foi a que produziu o menor RMSE. Além disso, o nível de decomposição foi escolhido de acordo com o critério de Nourani *et al* (2009), no qual o nível é igual a parte real do  $\log_{10}(n)$ , sendo  $n$  o número de registros da série temporal. Assim, o último parâmetro a ser ajustado foi a ordem do preditor, o qual foi escolhido também de acordo com o menor RMSE produzido. Os valores para o RMSE dos modelos gerados utilizando a wavelet de Meyer e variando o número do preditor estão representados na Figura 6.

A partir do gráfico gerado, é fácil perceber que a melhor ordem para ser usada é a de número 4, uma vez que para as ordens de 5 e 6 o RMSE praticamente se manteve constante e para 7 o valor do RMSE aumentou. Embora os valores do RMSE tenham sido melhores para as ordens de 5 e 6, é preferível que o modelo permaneça o mais simples possível, o que reduzirá o tempo computacional de operação.

Com o modelo já definido, foi possível obter as medidas de erro apresentadas na Tabela 2; os critérios para avaliação da aderência do modelo aos dados originais foram o RMSE, o Nash-Sutcliffe-Efficiency - NSE e o coeficiente de determinação  $R^2$ . Além disso, para comprovar a eficiência do pré-processamento dos dados de entrada da rede neural através da transformada wavelet discreta, foram

comparados os critérios de erro acima para um modelo utilizando uma rede neural autorregressiva, sem pré-processamento, e o valores retornados pelo modelo utilizado neste trabalho.

A sobreposição das séries previstas pelos dois modelos, assim como também os valores reais registrados em um horizonte de 120 dias estão apresentados na Figura 5.

Figura 6: Escolha da ordem do preditor.

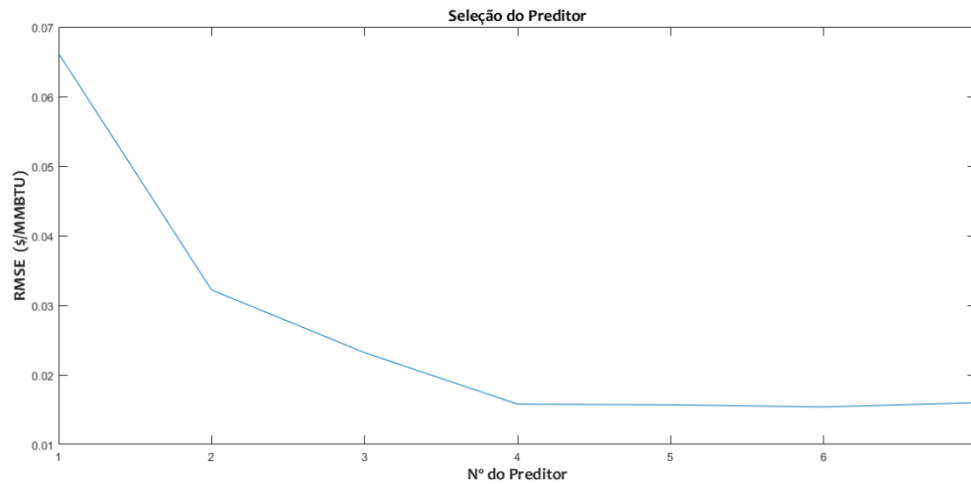



Tabela 2: Comparação dos modelos.

MODELO	RMSE (\$/MMBTU)	R <sup>2</sup>	NSE
RNA – Wavelet	0.0158	0.976	0.991
RNA	0.2248	0.799	0.797

Figura 5: Sobreposição das séries simuladas com a série original.



## Conclusões

A partir dos testes realizados, foi possível verificar que a transformada wavelet discreta potencializou, de fato, a habilidade preditiva da rede neural frente à série temporal de preços de gás natural. O modelo desenvolvido retornou medidas de erro relativamente pequenas, o que permite afirmar que este foi capaz de realizar o prognóstico desejado, se comportando bem no horizonte de previsão testado. Assim, tal estratégia aliada a outras metodologias como, por exemplo, a análise técnica, pode compor um sistema de apoio à tomada de decisão dentro de um sistema de gestão que aumente a precisão das estimativas para os preços do gás natural do *Henry Hub*.

## Agradecimentos

Laboratório de Sistemas Inteligentes Aplicados - LABSIA

Universidade Federal de Alagoas - UFAL

## Referências Bibliográficas

ANHISH, M.; RASHMI, B. Prediction of daily air pollution using wavelet decomposition and adaptive-network-based fuzzy inference system. **International Journal of Environmental Sciences**, v. 2, n. 1, 2011.

JIN, J.; KIM, J. Forecasting natural gas prices using wavelets, time series, and artificial neural networks. **Plos one**, 2015.

HAYKIN, S.S. Redes Neurais: Princípios e Prática. 2 ed. Bookman Companhia Ed, 2001.

LIANG, F. et al, The role of natural gas as a primary fuel in the near future, including comparisons of acquisition, transmission and waste handling costs of as with competitive alternatives. **Chemistry Central Journal**, 2012, 6(Suppl 1):S4.

NOURANI, V.; KISI, O.; KOMASI, M. Two hybrid artificial intelligence approaches for modeling rainfall-runoff process. **Journal of Hydrology**, v. 402, p. 41-59, 2011.

PARODI, G. W.; DALE, L.; LEVOK, A. Comparing price forecast accuracy of natural gas models and futures markets. **Energy Information Administration's Annual Energy Forecast Evaluation**, Junho 2005.