

SISTEMA AUTOMÁTICO DE DETECÇÃO E DIAGNÓSTICO DE FALHAS EM SENSORES INDUSTRIAIS UTILIZANDO *DEEP NEURAL NETWORKS*

¹Bruno Carlos Vieira dos Santos; ² Lucas Costa Barreto; ³ Renor Bernardo Silva; ⁴ Frede de Oliveira Carvalho
¹brunocarlos343@hotmail.com; ²lucascosta_108@hotmail.com 1; ³renor.bernardo@hotmail.com; ⁴e-mail do coautor 3
^{1,2,3,4}Universidade Federal de Alagoas; Av. Lourival Melo Mota, S/N; 57072-900 ; Maceió; Alagoas; Brasil

RESUMO: *O contínuo avanço tecnológico dentro do ambiente industrial vem possibilitando a execução de processos mais complexos e menos manuais. Atrélada a essa realidade, a presença de sistemas de controle e monitoramento das plantas se tornou corriqueira. Sendo assim, é necessário que se garanta a integridade das informações enviadas ao sistema de comunicação industrial para que a rede de controle e monitoramento opere sem falhas que comprometam a produção. Visando atender a essa necessidade, esse trabalho propôs a utilização de técnicas baseadas em inteligência artificial, mais especificamente as Deep Neural Networks, para criação de um sistema de detecção e diagnóstico de falhas em sensores industriais. O Estudo de caso foi realizado em sensores instalados em uma coluna debutanizadora que opera em uma planta de dessulfurização. O modelo se mostrou satisfatório na detecção e diagnóstico das falhas nos sensores, obtendo a precisão de 92,9% em sua resposta. Além disso, o sistema foi implementado em interface gráfica para simular um painel de controle que possa servir de apoio ao operador do equipamento.*

PALAVRAS-CHAVE: *Sensores; Classificação; Redes Neurais*

1 INTRODUÇÃO

Em meados da década de 60, o intuito de se obter uma maior segurança nos processos industriais, aliada à redução de custos e menor presença humana em etapas repetitivas fez crescer o interesse por automatizar diversas tarefas nas plantas de produção. (Isermann, 2006). Nesse contexto, sistemas de controle cada vez mais complexos, precisos e eficientes surgiram para atender os diversos tipos de necessidades dentro dos processos. Por outro lado, uma grande variedade de sensores industriais capazes de monitorar parâmetros da planta e enviar informações à rede de comunicação foi progressivamente ocupando o ambiente fabril.

Nessa perspectiva, tais equipamentos começaram a desempenhar um papel crucial dentro dos sistemas de monitoramento e controle (Kadlec et al., 2009), acompanhando o estado do processo e dando suporte de forma contínua. Portanto, é imprescindível que se garanta o perfeito funcionamento de tais componentes e se detectem comportamentos anormais (Filho et al. 2011; Jan et al. 2017), uma vez que medições imprecisas e o mau desempenho destes podem comprometer toda a cadeia de operação da planta (Kusiak e Song 2009; Gao et al. 2015).

À medida que os sensores industriais monitoram as diversas variáveis do processo, também

possibilitam o armazenamento de grandes quantidades de dados sob a forma de históricos. Dessa maneira, várias estratégias de análise e processamento de dados têm sido utilizadas para reconhecer padrões que auxiliem na identificação de falhas em sensores. Nesse cenário, alguns algoritmos de inteligência artificial, como Máquina de vetores de suporte, Mapas Autoorganizáveis e Redes Neurais Artificiais, em conjunção com técnicas de redução de dimensionalidade, como a Análise por Componentes Principais (Kusiak e Song, 2009; Brandão, 2010; Gao et al., 2015), têm demonstrado serem ferramentas eficientes na resolução desse tipo de problema, uma vez que a redução de dimensionalidade resulta em uma forma direta de simplificação do sistema, diminuindo o grau de complexidade desses.

Nos últimos anos, a literatura tem reportado o uso promissor de *Deep Neural Networks*, DNN, aplicadas a problemas de reconhecimento de fala, escrita e processamento de imagens (Rocha, 2015; Righetto, 2016; Rawat e Wang, 2017). Uma peculiaridade desse tipo de modelo é o fato de possuir em sua estrutura interna mecanismos que propiciam a extração de características, remoção de ruído e identificação de padrões, o que possibilita a eliminação de etapas de pré-processamento para os dados em estudo.

Sendo assim, esse trabalho buscou investigar a aplicação das DNN, técnica baseada em inteligência artificial oriunda do conceito de *deep-learning*, utilizando-as para o problema de detecção e diagnóstico de falhas em sensores. Para tal, foram utilizados registros de sensores de uma coluna debutanizadora, obtidos em Isermann, 2006. Além disso, o sistema foi implementado em aplicação gráfica, simulando um painel de controle que poderia vir a servir de auxílio para os operadores do equipamento.

1.1 REDES NEURAIS ARTIFICIAIS (RNA's)

As Redes Neurais Artificiais (RNA's) são algoritmos computacionais inspirados no cérebro humano no que se refere à sua capacidade de receber informações, armazená-las e estabelecer relações entre elas para produzir conhecimento que ficará disponível posteriormente. Uma de suas peculiaridades é a habilidade de lidar com problemas determinísticos sem a exigência de conhecimento prévio da natureza fenomenológica do sistema. Tal característica se deve ao fato de que os neurônios da rede podem fornecer respostas não lineares, o que possibilita o mapeamento de relações multivariáveis de entrada e saída (Haykin, 1999).

Os componentes mais simples da rede neural, os neurônios artificiais, realizam seus cálculos baseando-se nas informações de entrada, realizando o somatório do produto entre os vetores de entrada X e os respectivos pesos sinápticos W_j e subtraindo a ativação residual interna (bias), b , para calcular o campo local induzido, ϕ . Por fim, o resultado dessa operação é levado a uma função de transferência que restringirá o sinal de saída, y , dentro de um intervalo característico (Bezerra, 2014).

$$\phi = \left(\sum_{i=1}^n (W_{ij} \cdot a_i - b) \right) \quad (1)$$

$$y_j = f(\phi) \quad (2)$$

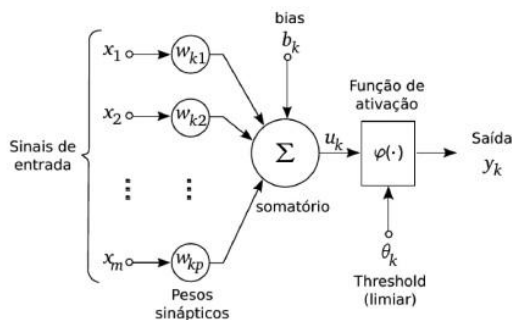
Vale salientar que as funções de transferência dos neurônios podem assumir a forma de diversas expressões matemáticas.

A saída y então é propagada juntamente com outras respostas de outros neurônios e o processo de combinação com os pesos e produção de uma saída é repetido até a última camada da rede neural.

Inicialmente, a rede do tipo perceptron simples, de um único neurônio, foi criada visando a solução do problema de classificação binária. Posteriormente, com o avanço da computação, as redes neurais do tipo perceptron multicamadas, com mais camadas e mais neurônios, foram introduzidas e propiciaram a resolução de problemas mais complexos de classificação e também regressão (Haykin, 1999). Na arquitetura da rede, o número de neurônios de entrada e saída são definidos pelo problema a ser estudado e o número de camadas ocultas é definido na solução do problema (Brandão, 2010).

O processo de aprendizado da rede neural se dá, basicamente, pelo ajuste iterativo dos pesos sinápticos, através da minimização de uma função de erro preestabelecida, utilizando-se algum algoritmo de otimização. Dessa forma, quando o processo de treinamento é encerrado, a rede é capaz de fornecer resposta a um vetor de entrada até então desconhecido. A Figura 1 ilustra o neurônio artificial, peça mais básica de uma rede neural artificial.


Figura 1: Neurônio Artificial



1.2 DEEP NEURAL NETWORKS

Redes Neurais de Aprendizagem Profunda, também conhecidas como *Deep Neural Networks* são redes neurais com múltiplas camadas intermediárias. Como característica única, tais camadas têm o objetivo de realizar a extração de características, identificação de padrões e até mesmo remoção de ruídos dos dados de entrada. Tais procedimentos auxiliam na redução de complexidade do sistema e refletem em um melhor desempenho do modelo. Neste trabalho, as camadas intermediárias utilizadas na *Deep Neural Network* são denominadas *Autoencoders*. Após os dados de entrada serem processados nos *Autoencoders* são então passados ao classificador que realiza a tarefa final tal como uma rede neural convencional. A Figura 2 apresenta a arquiteturas das *Deep*

Figura 2: Arquitetura de uma *Deep Neural Network*.




1.3 AUTOENCODERS

Autoencoders são também uma classe de redes neurais artificiais. Isto é, apresentam uma camada de neurônios de entrada, uma camada intermediária e uma camada de saída. Os autoencoders, por outro lado, são treinados para produzir valores de saída iguais aos de entrada. Tal procedimento possibilita que a camada intermediária, que geralmente possui menos neurônios que a camada de entrada, “aprenda” uma representação comprimida dos dados, o que resulta na redução de dimensionalidade. Além disso, esse processo leva também à remoção de características irrelevantes, o que torna a posterior classificação mais eficiente. Uma característica que distingue significativamente essa técnica da análise por componentes principais é a manutenção das relações não lineares que não ocorre com a utilização do PCA.

A Figura 3 ilustra a arquitetura de um *Autoencoder*. Os dados de entrada passam por uma camada intermediária que é responsável por extrair características e identificar padrões. Além disso, esse processo pode ser repetido, bastando apenas apresentar a versão reduzida dos dados a outro *Autoencoder* e então uma versão ainda mais reduzida poderá ser obtida.

Figura 3: Arquitetura de um *Autoencoder*.

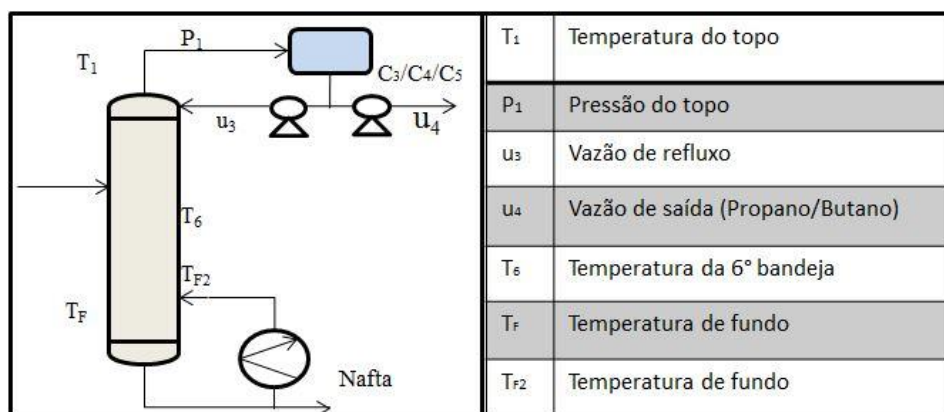


2 METODOLOGIA

2.1 DESCRIÇÃO DO CONJUNTO DE DADOS

A coluna debutanizadora em estudo opera em uma planta de desulfurização e separação de nafta, a Figura 4 mostra o esquema da coluna e as variáveis envolvidas nessa etapa do processo.

Figura 4: Esquema de uma coluna debutanizadora e variáveis inerentes ao processo.



Devido a frequente ocorrência de falhas em sensores de temperatura e pressão, estes foram considerados para o estudo de caso. No total, o conjunto de dados continha 2394 registros referentes às medições contínuas realizadas no equipamento dentro de um determinado intervalo de tempo.

2.2 SIMULAÇÃO DAS FALHAS E CONSTRUÇÃO DO MODELO

Foram inseridas, aleatoriamente, falhas nas medições dos sensores de temperatura de topo e pressão de topo, dentro de um intervalo de 30% em relação ao valor real, para mais ou para menos. Apesar do conjunto de dados disponível ser constituído de 2394 elementos, foram gerados mais vetores de entrada a partir da inserção das falhas. O novo conjunto de dados utilizado para construção do modelo passou a ter então 7182 elementos. Desses, 85% foram inseridos na fase de treinamento da rede neural e os demais utilizados na fase de validação.


A rede neural foi treinada tanto com os dados originais da operação, quanto com aqueles nos quais foram simuladas as falhas. Dessa forma, o modelo aprendeu a indicar a ocorrência de falhas e diagnosticar em quais sensores, especificamente, essas estariam ocorrendo. Sendo assim, havia quatro classes possíveis das quais um vetor de entrada contendo as sete variáveis de processo poderia fazer parte, sendo elas:

- Classe 1: Falha no sensor de pressão de topo;
- Classe 2: Falha no sensor de temperatura de topo;
- Classe 3: Funcionamento normal do sistema;
- Classe 4: Falha simultânea dos sensores;

Todo o sistema de detecção de falhas, desde a simulação das falhas e treinamento do modelo foi desenvolvido utilizando a ferramenta MATLAB®.

Na arquitetura escolhida para a *Deep Neural Network*, foram utilizados 2 *Autoencoders*, com 3 neurônios na camada intermediária do primeiro e 2 neurônios na camada intermediária do segundo. O número de *Autoencoders* utilizados, assim como também a quantidade de neurônios em cada um deles foram parâmetros ajustados através de métodos heurísticos. O algoritmo utilizado para a otimização dos vetores de peso da rede neural foi o de *levenberg-maquardt*. A Figura 4 apresenta a arquitetura do modelo construído.

Figura 4: Arquitetura do modelo.



2.3 CONSTRUÇÃO DO PAINEL DE CONTROLE

Após o desenvolvimento do modelo neural, este foi implementado em um painel de controle, construído através da biblioteca de interface do MATLAB.

O painel de controle foi composto de dois marcadores, um para a temperatura de topo e outro para a pressão de topo, um interruptor para ativar o recebimento de dados dos sensores que seriam monitorados e realizar o diagnóstico de falhas, e duas lâmpadas que emitem luz verde ou vermelha, dependendo do estado do sensor. Caso o sistema acuse falha, a luz vermelha deve ser emitida pela lâmpada correspondente àquele sensor danificado.

3 RESULTADOS E DISCUSSÃO

3.1 DESENVOLVIMENTO DO SISTEMA DE DETECÇÃO E DIAGNÓSTICO DE FALHAS

Na fase de validação da rede neural, foram utilizados registros não apresentados na etapa de treinamento. Dessa forma, foi possível se verificar a capacidade de generalização do modelo.

O desempenho do modelo pode ser traduzido através da matriz de confusão gerada na etapa de validação. Esta pode ser vista na Figura 5.

Figura 5: Matriz de confusão do modelo de detecção de falhas.

Matriz de Confusão

1	150 13.9%	0 0.0%	7 0.6%	6 0.6%	92.0% 8.0%
2	2 0.2%	187 17.4%	8 0.7%	2 0.2%	94.0% 6.0%
3	3 0.3%	4 0.4%	510 47.4%	30 2.8%	93.2% 6.8%
4	10 0.9%	0 0.0%	4 0.4%	154 14.3%	91.7% 8.3%
	90.9% 9.1%	97.9% 2.1%	96.4% 3.6%	80.2% 19.8%	92.9% 7.1%
	1	2	3	4	

A partir da Figura 5 é possível ver o percentual de acertos na classificação do modelo na fase de validação. Para a primeira classe, a qual representa a existência de falha no sensor de temperatura de topo, foram utilizados 165 vetores de entrada. Desses 165 casos de análise, 150, ou 90,9%, foram classificados corretamente, ou seja, como pertencentes ao Caso 1. Os outros 9,1% foram classificados erroneamente.

Para a segunda classe, 191 vetores de entrada foram apresentados, dos quais 187 foram classificados corretamente, correspondendo a 97,9% do conjunto. A classe três, que representa a operação normal do sistema, foi identificada corretamente em 510 casos, de um total de 529 apresentados para validação. Por último, o Caso 4 foi testado 192 vezes, das quais 154 foram classificadas corretamente.

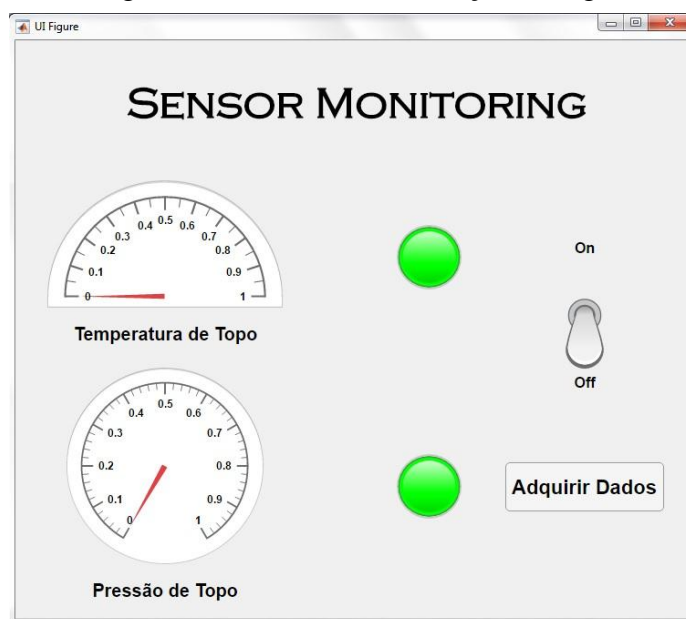
No total, de 1077 vetores de entradas utilizados para validar o modelo, 1001 foram classificados corretamente, correspondendo a 92,9% de acerto. Os outros 7,1% representam a taxa de erro do modelo. É importante destacar ainda que apenas 1,76% dos conjuntos de entrada ocasionaram em alarmes falsos, isto é, foram classificados como casos de falha em situações que correspondiam à normalidade de operação do processo. Além disso, em 3,34% dos casos, o sistema classificou como normal uma situação em que havia falha nos sensores. Nessa perspectiva, o modelo construído pode ser considerado satisfatório, visto que este foi capaz de identificar falhas e diagnosticar os componentes defeituosos na operação.

3.2 CONSTRUÇÃO DA APLICAÇÃO GRÁFICA

Após o desenvolvimento do sistema de detecção e diagnóstico de falhas, a rede neural foi implementada dentro de uma interface gráfica, com o objetivo de simular o funcionamento do sistema em um ambiente industrial. Para tal, a interface foi construída com a inserção de dois medidores, utilizados para exibir os valores registrados nos sensores de temperatura de topo e pressão de topo, duas lâmpadas de LED e um interruptor para ligar o sistema. A Figura 6 ilustra a interface gráfica desenvolvida.

O botão de adquirir dados serve para ativar o recebimento de dados dos sensores de temperatura e pressão e o interruptor inicia o processo de análise dos dados recebidos. A interface deve emitir luz verde ou vermelha, através dos LEDs instalados, a depender do estado de cada sensor no momento da análise. Em caso de falha, a luz vermelha deve ser emitida pelo LED associado ao sensor. É importante salientar que devido à existência do erro de 7,1% inerente ao modelo neural criado para análise, haverá casos em que a luz do LED mudará de cor, sem exatamente representar o real estado de funcionamento dos sensores. Estes casos, porém, poderão ser facilmente identificados, uma vez que quando ocorrerem não se sustentarão, ou seja, a tendência é que o LED mude de cor repentinamente e retorne a cor anterior.

Figura 6: Interface gráfica do sistema de detecção e diagnóstico de falhas.



4 CONCLUSÕES

Neste trabalho foi verificada a eficácia das *Deep Neural Networks* no problema de detecção e diagnóstico de falhas em sensores de equipamentos. Além disso, o modelo desenvolvido foi implementado em interface gráfica para simular o ambiente de monitoramento industrial por meio de um painel de controle.

Dentro desse contexto, o modelo neural desenvolvido se mostrou eficiente ao apresentar uma taxa de acerto igual a 92,9% em sua fase de teste. Se levarmos em consideração ainda que apenas 1,76% das vezes o sistema produziu alarmes falsos e que em 3,74% das ocasiões este não foi capaz de detectar a falha existente, é possível afirmar que o sistema proporciona uma resposta segura e confiável, sendo assim, capaz de funcionar como uma ferramenta de suporte aos operadores, garantindo o bom funcionamento da coluna debutinizadora e a segurança do processo.

5 REFERÊNCIAS

KADLEC, P.; GABRY, B.; STRANDT, S. Data-driven Soft Sensors in the process industry. Computers and Chemical Engineering. 2009.

GAO, Z.; CECATI, C.; DING, S. X. A Survey of Fault Diagnosis and Fault-Tolerant Techniques - Part II: Fault Diagnosis With Knowledge - Based and Hybrid/Active Approaches. *IEEE Transactions On Industrial Electronics*, Vol. 62, N° 6, 2015.

JAN, S. U.; LEE Y.; SHIN, J.; KOO, I. Sensor Fault Classification Based on Support Vector Machine and Statistical Time-Domain Features. *IEEE Access*, vol. 5, ph. 8682-8690, 2017.

RAWAT, W.; WANG, Z. Deep Convolutional Neural Networks for Image Classification: A Comprehensive Review. *Neural Computation*, 2017.

KUSIAK, A.; SONG, ZHE. Sensor Fault Detection in Power Plants. *Journal of Energy Engineering*, pg 127-136, 2009.

BEZERRA, L. G. S. Detecção, Diagnóstico e Correção de Falhas em Sensores Industriais Foundation Fieldbus Utilizando Agentes Inteligentes. 2014. Dissertação (Mestrado em Ciência e Engenharia do Petróleo) – Centro de Ciências Exatas e da Terra, UFRN, 2014.

BRANDÃO, M. M. S. L. Detecção e Diagnóstico de Falhas de Processo Químico Dinâmico Por Redes Neurais Artificiais Multicamadas e Mapas Auto-organizáveis. 2010. Dissertação (Mestrado em Ciências) – Escola de Química, UFRJ, 2010.

ROCHA, R. H. S. Reconhecimento de Objetos por Redes Neurais Convolutivas. 2015. Dissertação - Departamento de Informática, PUC-Rio, 2015.

FILHO, A. M. P. P.; LOPES, K. R.; DA SILVA, V. L. C. M.; MARTINS, D. L.; NETO, A. D. D.; DE MELO, J. D.; GUEDES, L. A. Diagnóstico de Falhas em Sensores Usando Redes Neurais: Implementação em Rede Industrial Foundation Fieldbus. In: 10th Brazilian Congress On Computational Intelligence (CBIC 2011), 2011.

RIGHETTI, G. O Uso da Rede Neural Convolucional Como Extrator de Características Aplicado ao Problema de Identificação de Escritores. 2016. Trabalho de Graduação. (Graduação em Ciência da Computação) – UTFPR, Campo Mourão, 2016.

AGRADECIMENTOS

Ao Laboratório de Sistemas Inteligentes Aplicados – LABSIA e ao Programa Especial de Capacitação Discente – PEC.